



冶金自动化
Metallurgical Industry Automation
ISSN 1000-7059, CN 11-2067/TF

《冶金自动化》网络首发论文

题目：基于非线性自回归神经网络的烧结混合料水分智能控制
作者：吴岳明，聂慧远，吴朝霞
收稿日期：2020-04-09
网络首发日期：2020-11-16
引用格式：吴岳明，聂慧远，吴朝霞．基于非线性自回归神经网络的烧结混合料水分智能控制．冶金自动化．
<https://kns.cnki.net/kcms/detail/11.2067.TF.20201116.1106.010.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

•人工智能技术•doi: 10.3969/j.issn.1000-7059.2021.01.005

基于非线性自回归神经网络的烧结混合料水分智能控制

吴岳明¹, 聂慧远², 吴朝霞³

(1. 宝钢股份上海梅山钢铁股份有限公司设备部, 江苏 南京 210039; 2. 宝钢股份上海梅山钢铁股份有限公司炼铁厂, 江苏 南京 210039; 3. 东北大学秦皇岛分校控制工程学院, 河北 秦皇岛 066004)

摘要: 为提高烧结混合料加水控制的智能程度, 针对烧结生产线现场的实际情况, 提出了一种非线性自回归 (nonlinear autoregressive models with exogenous inputs, 简称 NARX) 神经网络加水前馈控制模型。首先, 利用工厂的历史生产数据和物料平衡原理建立烧结混合料的加水模型, 其中涉及各种原料量及混合加水量; 然后, 将深度监督学习与自学习 NARX 算法结合, 建立烧结混合料水分预测模型; 最后, 将 NARX 水分预测模型与极限学习机 (extreme learning machine, 简称 ELM) 模型进行对比。结果表明, NARX 算法在水分控制的准确性、平稳性上均更优, 可以为烧结混合料加水前馈控制提供新的解决方案。

关键词: 烧结混合料; 深度学习; 非线性自回归; 前馈控制

文献标志码: A

Intelligent control of sintering mixture moisture based on NARX neural network

WU Yueming¹, NIE Huiyuan², WU Zhaoxia³

(1. Equipment Department, Shanghai Meishan Iron and Steel Co., Ltd. of Baosteel, Nanjing 210039, China; 2. Ironmaking Plant, Shanghai Meishan Iron and Steel Co., Ltd. of Baosteel, Nanjing 210039, China; 3. School of Control Engineering, Northeastern University at Qinhuangdao, Qinhuangdao 066004, China)

Abstract: To improve the intelligence of the moisture control of the sintered mixture, a NARX neural network water feedforward control model was proposed for the actual situation of the sintering line. Firstly, the plant's historical production data and material balance principle are used to establish the mixture adding water model, which involves various raw material quantities and mixed water addition. Then, the depth supervision learning is combined with the self-learning NARX algorithm to establish the moisture prediction model of the sintering mixture. Finally, compared with the ELM model, the NARX algorithm is superior in the accuracy and stability of moisture control, and can provide a new solution for water feedforward control of sintered mixture.

Key words: sintered mixture; deep learning; NARX; feedforward control

0 引言

钢铁工业的烧结是将各种矿粉、溶剂以及燃料按一定的比例混合, 之后在混合机中加入适量的水, 最后在烧结机上进行烧结。混合料中的水分起着黏结、润滑和导热作用。如果水分含量过高, 不仅会使点火效果受到影响, 导致生产率降低, 各种消耗增加, 而且会因制粒效果变差而导致料层透气性下降; 如果水分含量过低, 则会导致混合料成球性变差, 进而引起返矿量增大, 转鼓系数下降, 最终影响烧结矿的产量和质量^[1]。因此, 稳定控制混合料水分含量具有十分重要的意义。

基金项目: 河北省自然科学基金资助项目(F2017501041); 中央高校基本科研业务费资助项目(N172304030)

作者简介: 吴岳明 (1972—), 男, 高级工程师, 大学本科; 收稿日期: 2020-04-09

对于烧结水分控制，国内外学者做了很多的研究，并取得了一定的成果。文献[2]采用专家系统对烧结水分进行控制，由于当时专家系统的知识库不完善，导致控制效果并不是十分理想。文献[3]提出了一个在线识别水分含量和原料的蒸发系数的模型，通过神经网络进行水分控制，但当时没有通用的方法来设计神经网络，导致建立的神经网络模型不精确，仿真效果不是很好。文献[4]通过神经网络PID控制器，解决了混合料加水控制中存在的滞后问题，但是系统的模型很难确定。

近年来，非线性大系统控制问题引起了人们的广泛关注^[5-6]。文献[6]提出了一种新型的模糊自适应输出反馈分散最优控制方案。该非线性大系统包含未知的非线性函数和未测量的状态。NARX神经网络与完全连接的递归神经网络一样强大，在非线控制应用和其他问题中应用很多^[7]。NARX网络的反馈来自输出神经元，而不是来自隐含层^[8]。它已成功应用于许多领域^[9-12]，如NARX-Laguerre模型^[9]、模式分类器^[10]、质子交换膜燃料电池控制^[11]、频域收敛界^[12]等。综上所述，本文提出一种基于NARX神经网络的烧结混合料加水前馈控制算法，并将其与ELM进行了仿真实验对比。

1 烧结混合料水分含量模型

在烧结生产过程中，混合料包括矿粉、煤粉、炼铁返矿、石灰石、白云石、生石灰、烧结返矿、高炉灰、除尘、人工加水等。混合后的含水量在二次混合机出口进行测量，其关系模型为

$$M(t) = \frac{\sum_{i=1}^n K_i(t) \times W_i(t) + D(t)W_r(t) + u(t)}{\sum_{i=1}^n W_i(t) + W_r(t) + u(t)} \quad (1)$$

式中： $M(t)$ 为混合料水分含量； n 为物料种类的数量； $K_i(t)$ 为各个原料的含水量； $W_i(t)$ 为第 i 种物料的质量； $D(t)$ 为烧结返矿的含水量； $W_r(t)$ 为烧结返矿的质量； $u(t)$ 为加水量。

由于受天气、物料来源及生产需要的影响，物料含水量及质量会随时间非线性的缓慢变化。例如，在夏季阴雨天中，空气中湿度的增加会导致物料含水量的变化^[13]。另一方面，物料的含水量在短时间内不会发生剧烈变化，但是烧结返矿的含水量与上一时刻的混合料及加水量有关，从而导致整个系统呈现显著的非线性。因此，可以根据前一时刻的水分含量计算下一时刻的加水量，用式(32)来表示：

$$\begin{cases} M(i+1) = f_1[\omega_1(i), \omega_1(i-1), \dots, \omega_1(i-d_x)] \\ \omega_1 = [W_1, W_2, \dots, W_n]^T \end{cases} \quad (2)$$

式中： $M(i+1)$ 为下一时刻的水分含量； f_1 为非线性函数； W_j 为第 j 种物料的质量； $\omega_1(i-z)$ 为前 z 时刻的物料矩阵。

因此，可以通过以下公式计算加水量：

$$u(t) = \frac{[g - M(i+1)] \times [\sum_{i=1}^n W_i(t) + W_r(t)]}{1 - g} \quad (3)$$

式中： g 为目标水分值。

此外，混合机的惯性特性造成了系统的延迟。在配料过程中，各料仓与混合机之间的距离不同，因此在同一时间点测量的每种物料的质量不属于同一加水过程。从加水到测量混合物的水分含量，需要两个混合过程，约耗时 8 min。

2 NARX 水分控制模型

2.1 NARX 神经网络的结构

NARX 网络是一种动态递归网络，通过引入延时模块及反馈实现对系统模型的建立。它由具有反馈连接的多个层组成，包含外部输入量和输出量的时间序列，具有更丰富的历史状态信息和优秀的动态特性，被广泛用于非线性动态系统识别和建模^[14]。NARX 模型的数学公式 $y(n+1)$ ^[8] 可以表示为

$$y(n+1) = \varphi(x(n-d_x), \dots, x(n-1), x(n), y(n-d_y), \dots, y(n)) \quad (4)$$

式中： $x(n)$ 、 $y(n)$ 分别为系统在 n 时刻的输入和输出； d_x 、 d_y 分别为输入和输出次序； $x(n-i)$ 、 $y(i)$ 分别为前 i 时刻的输入输出， $i=0,1,\dots,d_x$ ； φ 为一个非线性映射函数， $d_x \geq 1$ ， $d_y \geq 1$ 。

NARX 的输出可以完全进一步展开写成

$$y(n+1) = \varphi_0 \left[b_0 + \sum_{h=1}^{Nh} W_{h0} \varphi_h(b_h + \sum_{i=0}^{d_x} W_{ih} x(n-i) + \sum_{j=0}^{d_y} W_{jh} y(n-j)) \right] \quad (5)$$

式中： w_{h0} 、 w_{ih} 和 w_{jh} 为网络权重向量； $j=0,1,\dots,d_y$ ； $h=1,2,\dots,Nh$ ； b_0 、 b_h 为偏置向量； φ_0 、 φ_h 为输出层和隐含层的激活函数。

NARX 模型一般具有两种结构，即串行-并行体系结构和并行体系结构。图 1 所示为一个分别具有一个输入层、隐含层和一个输出层的 NARX 神经网络的串-并行结构。 d_x 和 d_y 分别是延迟输入和输出。

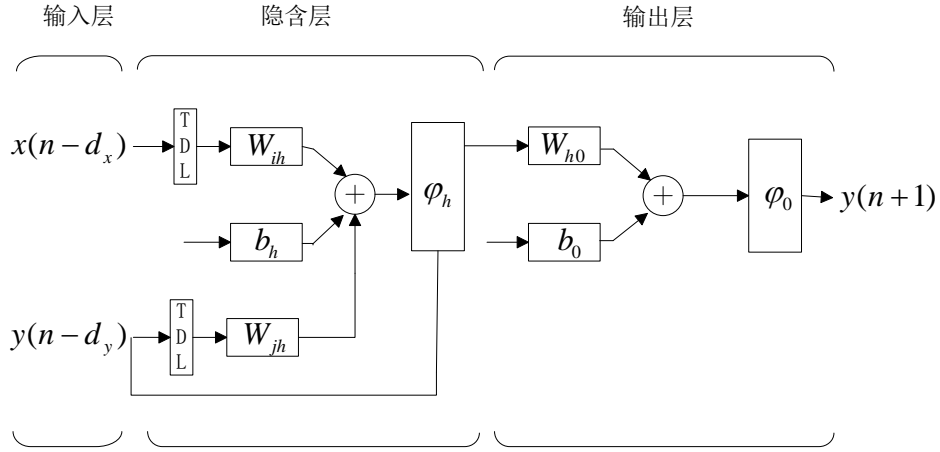


图 1 NARX 体系结构

Fig.1 Architecture of NARX

2.2 水分控制算法

针对水分控制过程，提出了一种离线训练与在线训练相结合的训练方法。采用离线训练模式建立水分含量预测的 NARX 基本模型，在线训练模式用于改进 NARX 基本模型。首先，对 NARX 进行离线训练，以获得一个基本模型；然后，采用在线训练算法代替离线训练算法来改进基本 NARX。换句话说，首先在离线模式下为 NARX 提供足够的数据信息，当模型工作后，将其切换到在线模式以进行自学习。

烧结控制系统中含有大量的物料量、人工加水量和水分测量等历史运行数据，因此可以通过适当的离线训练算法来充分利用这些数据，得到基本的 NARX 模型。具体地，对于加水控制过程，离线 NARX 网络的输入 $\text{Input}(n)$ 由混合权重向量 $x(n) = (x_1(n), \dots, x_7(n))^T$ 、加水权重 $u(n)$ 和输出水分 $y(n)$ 以及它们的延迟组成，可以表示为

$$\text{Input}(n) = [x(n-d_x), \dots, x(n), u(n-d_x), \dots, u(n), y(n-d_y), \dots, y(n)]^T \quad (6)$$

NARX 网络的输出 $\text{Output}(n)$ 定义为

$$\text{Output}(n) = \hat{y}(n) \quad (7)$$

采用 Levenberg Marquardt(LM)算法进行离线 NARX 模型训练，以实现有效的监督学习。LM 是一种快速可靠的二阶局部方法，它结合了最速下降法（一阶）和高斯-牛顿（二阶）方法的优点。它的权重更新公式为

$$W_{h+1} = W_h - (H_h + \mu I)^{-1} J_h r_h \quad (8)$$

式中： W 为权重矩阵； h 为迭代次数； H 为 Hessian 矩阵； μ 为变量标量； I 为单位矩阵； J_h 为雅可比矩阵； r_h 为残差误差向量。

根据采集到的数据，约有 700 万个训练样本可供使用。但是，仅仅根据有限的历史运行

数据，还不能使模型完全拟合实际烧结混合过程。因此，应该建立一个在线的自我学习机制。对于在线 NARX 模型，训练集来自近 8 min 的实时数据。一方面，在线学习模式强调对系统动态行为的实时学习和跟踪；另一方面，离线 NARX 模型已经学习了大多数系统特性，因此不需要大量更新或短时间内大量学习。

3 模型训练

采集了工厂 2018 年 1 月 1 日到 2019 年 12 月 31 日近两年的数据，传感器每 4 s 采集一次数据，总共获得 12 096 000 个样本，对其进行数据值乘以十倍等相应的预处理，部分数据见表 1。

表 1 物料量和测量水分记录
Table 1 Material quality and measurement moisture records

时刻 s	烧结返矿 /(t · h ⁻¹)	石灰石 /(t · h ⁻¹)	生石灰 /(t · h ⁻¹)	炼铁返矿 (t · h ⁻¹)	...	人工加水量 /(t · h ⁻¹)	水分测量值 /%	理论值/%
0	365	349	73	86	...	141	7.30	7.00
4	362	355	73	83	...	141	7.20	7.00
8	354	356	74	87	...	141	7.20	7.00
12	358	352	74	99	...	141	7.30	7.00
16	362	352	74	107	...	141	7.20	7.00
20	353	345	76	112	...	141	7.10	7.00
...

采集到的原始数据有 23 个料仓的物料量，经过相同物料的合并以及主成分分析（图 2），最终提取 7 种物料作为影响混合料水分的主要因素。为了获得基本的 NARX 模型，将 7 种物料量和加水量作为输入变量，水分测量值作为输出变量，隐含层设置为 21 层，使用 Levenberg-Marquardt 算法进行训练。在隐含层中，选择 sigmoid 函数作为神经元的激活函数。在训练过程中，将 90% 的数据作为训练集、5% 的数据作为验证集、剩余 5% 作为测试集。选取训练集上的部分数据，获得 NARX 输出响应如图 3 所示。




图 2 主成分分析图

Fig.2 Diagram of principal component analysis




图 3 输出结果对时间序列的响应

Fig.3 Output response to time series

由图 3 可以看出，NARX 模型输出结果的误差很小，主要分布在 0 左右。

样本 $\{e_1, e_2 \dots e_n\}$ 的 k 阶自相关系数公式为

$$\rho_k = \frac{\sum_{t=1}^{n-k} (e_t - \bar{e})(e_{t+k} - \bar{e})}{\sum_{t=1}^n (e_t - \bar{e})^2} \quad (9)$$

其中

$$\bar{e} = \frac{\sum_{i=1}^n e_i}{n} \quad (10)$$

模型的残差自相关图如图 4 所示。可以发现残差具有短期相关性，大部分自相关系数都

落于置信区间内，可以认为残差序列具有平稳性。为了进一步确认残差是否是白噪声序列，对其进行 LB 检验，其 LB 统计量见式（11），该统计量服从卡方分布 $\chi^2(m)$ 。具体结果见表 2。




图 4 模型残差序列自相关图

Fig.4 Autocorrelation map of model residual sequence

$$LB = n(n+2) \sum_{k=1}^m \frac{\rho_k^2}{n-k} \sim \chi^2(m) \tag{11}$$

式中： n 为序列观测数； m 为指定的延迟阶数。

表 2 LB 检验结果

Table 2 LB test result

lag	χ^2	Df	p
1	0.030 407	1	0.861 6
6	3.129 9	6	0.792 4
12	13.713	12	0.319 4

注：lag 为延迟的阶数；df 为自由度。

表 2 中，由于假设检验的 p 值远远大于 0.01，表明该残差序列至少 12 阶内不具有自相关性，所以认为残差序列为白噪声序列。

图 5 的散点图表示的是 NARX 输出值与目标值在训练集、验证集、测试集以及整体数据上的相关性。在图 5 中，(a)、(b)和(c)分别表示训练集、验证集和测试集的回归，（d）表示整个数据集的回归。综合图 5 和表 2 可知，该模型已充分学习数据间的所有信息。

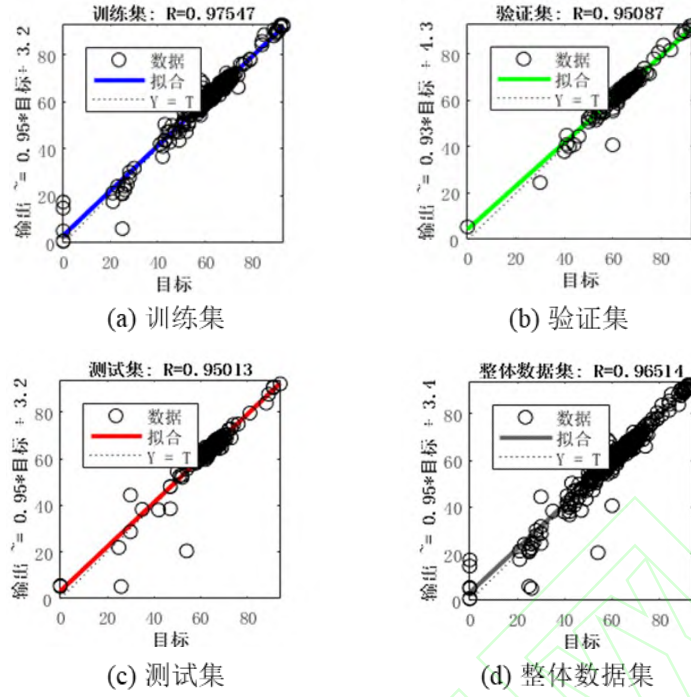


图 5 目标值和预测值之间相关性的散点图

Fig.5 Scatter plot of correlation between target and predict values

回归系数 R 的定义为

$$R = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \sum_{k=1}^n (y_k - \bar{y})^2}} \quad (12)$$

式中: n 为样本数; x_k 、 y_k 为测量数据; \bar{x} 、 \bar{y} 为数据的平均值。

当 R 值越大时, 代表数据训练的拟合效果越好。通过训练训练集得到混合物的水分模型, 使用验证集来防止模型过度拟合, 并通过小速率迭代修改模型的参数, 最后通过测试集确定模型的质量。

4 仿真实验

为了验证该模型的性能, 将 NARX 与 ELM 水分预测效果进行对比, 如图 6 所示。




图 6 NARX 与 ELM 模型效果对比

Fig.6 Effect comparison of NARX and ELM models

图 6 中，设测量值的时间序列为 y_i ，相应的预测序列为 $\hat{y}(i=1, \dots, N)$ ，其中序列的长度为 N 。残差的平均值为

$$\bar{e}_y = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i| \quad (13)$$

最大误差定义为

$$E_{\max} = \max_i \{|\hat{y}_i - y_i|\} \quad (14)$$

均方根误差 RMSE 定义为

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (15)$$

NARX 模型与 ELM 模型的性能指标见表 3。由图 6 和表 3 可知，对于所有指标，NARX 模型比 ELM 模型的性能更优越，前者的预测值更接近目标值。NARX 模型与 ELM 模型的残差平均值和标准差的比较表明，使用 NARX 模型预测的大多数混合料的水分含量比使用 ELM 模型更接近实际值。NARX 模型预测的水分含量的最大误差为 0.064，远小于 ELM 模型的 0.295。

表 3 NARX 模型和 ELM 模型性能指标

Table 3 Performance index of NARX model and ELM model

指标	$\bar{e}_y(t)$	$E_{\max}(t)$	$RMSE(t)$	R
NARX	0.022	0.064	0.026	0.96
ELM	0.077	0.295	0.097	0.74

为了能使物料的最终含水量接近设定值，根据已经训练出的模型预测出当前时刻的物料含水量，根据物料守恒，计算出当前理论上应该改变的加水量，公式为

$$\hat{u}(t) = \frac{(M_s(t) - \hat{M}(t)) \times \sum_{i=1}^7 W_i}{1 - M_s(t)} \quad (16)$$

式中： $\hat{u}(t)$ 为计算的改变加水量，正数表示增加加水量，负数表示减少加水量； $M_s(t)$ 为水分含量设定值； $\hat{M}(t)$ 为模型预测出的当前时刻的混合料的含水量。

按照式 (15) 调整加水量后，将新的加水量及物料量重新输入模型，获得调整加水量后混合料的含水量的预测值 $\tilde{M}(t)$ ，这即为模型在调整加水量后的水分含量预测值，并将作为下一时刻的历史信息，最终将 NARX 模型预测含水量的调整值与人工值进行比较，如图 7 所示。




图 7 调整值与人工值对比

Fig.7 Comparison of adjusted value and artificial value

根据数据统计结果可知,调整加水量后水分含量的标准方差为0.04,最大正偏差为0.24%,最大负偏差为0.21%,人工加水的水分含量的标准方差为0.25,最大正偏差为1.1%,最大负偏差为1.4%,所以调整加水量后烧结混合料的水分含量更加稳定且更接近设定值,与人工加水相比,正偏差减少了78%,负偏差减少了85%。结果表明,NARX预测调整加水要比人工加水更满足工业要求且波动更小。

5 结论

(1) 针对工厂烧结混合料加水控制的难点,利用 NARX 神经网络在非线性系统建模中具有动态递归特性,提出了 NARX 网络加水前馈控制模型。

(2) 通过利用实时和历史运行数据,考虑非线性和时间延迟,建立了自学习 NARX 算法来控制烧结混合料的水分。

(3) 与 ELM 算法对比,得出 NARX 神经网络的模型性能更优。进一步地,根据 NARX 模型预测的混合料含水量,调整加水量,并与人工加水控制比较,结果表明 NARX 预测调整加水要比人工加水更接近设定值且波动更小,满足生产工艺要求。

参考文献:

- [1] Loo C E, Wong D J. Fundamental insights into the sintering behaviour of goethitic ore blends[J]. ISIJ International, 2005, 45(4):459.
- [2] 黄天正, 范晓慧. 烧结生产控制专家系统[J]. 烧结球团, 1997, 22(5):1. (HUANG Tianzheng, FAN Xiaohui. The expert system for sintering production control[J]. Sintering and Pelletizing, 1997, 22(5):1.)
- [3] 孙乐, 金伟. 神经网络在烧结混合料水分控制中的应用[J]. 大连轻工业学院学报, 2003, 22(3):211. (SUN Le, JIN Wei. Neural network applied in moisture control for sinter

mixture[J]. Journal of Dalian Institute of Light Industry, 2003, 22(3):211.)

[4] Suman S, Giri B K, Roy G G. Mathematical modelling of iron ore sintering process using genetic algorithm: Effect of moisture evaporation and condensation on the temperature profile[J]. Journal of Fluorine Chemistry, 2013, 54(s1 - 3):1383.

[5] LI Yuanxin, YANG Guanghong, TONG Shaocheng. Fuzzy adaptive distributed event-triggered consensus control of uncertain nonlinear multiagent systems[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2019, 49(9):1777.

[6] TONG Shao-cheng, SUN Kang-kang, SUI Shuai. Observer-based adaptive fuzzy decentralized optimal control design for strict-feedback nonlinear large-scale systems[J]. IEEE Transactions on Fuzzy Systems, 2017:1.

[7] 吴涛, 吴崇, 曹加旺, 等. 基于 NARX 神经网络的高炉冶炼过程 Si 元素的预测与智能控制[J]. 当代化工, 2017(9):14. (WU Tao, WU Chong, CAO Jiawang et al. Prediction and intelligent control of Si element in blast furnace smelting process based on NARX dynamic neural network[J]. Contemporary Chemical Industry, 2017(9):14.)

[8] Abdelwahed I B, Mbarek A, Bouzrara K, et al. Nonlinear system modeling based on NARX model expansion on Laguerre orthonormal bases[J]. Iet Signal Processing, 2017, 12(2):228.

[9] ZHANG Jian-hua, YIN Zhong, WANG Ru-bin. Nonlinear dynamic classification of momentary mental workload using physiological features and NARX-model-based least-squares support vector machines[J]. IEEE Transactions on Human-Machine Systems, 2017, 47(4):536.

[10] 蒋传进, 宋福根. 基于 NARX 神经网络与 ARMA 的汇率混合预测模型[J]. 统计与决策, 2010(15):33. (JIANG Chuanjin, SONG Fugen. A hybrid forecasting model of exchange rate based on NARX neural network and ARMA[J]. Statistics and Decision, 2010(15):33.

[11] XIAO Zhenlong, JING Xingjian, CHENG Li. Parameterized convergence bounds for volterra series expansion of NARX models[J]. IEEE Transactions on Signal Processing, 2013, 61(20):5026.

[12] Schmidhuber, Jürgen. Deep learning in neural networks: An overview[J]. Neural Networks, 2015, 61:85.

[13] 吴敏, 王春生, 曹卫华. 基于预测模型与调整规则的烧结配料优化综合集成方法[J]. 系统仿真学报, 2008, 20(9):2423. (WU Min, WANG Chunsheng, CAO Weihua. Integrated

synthesis methodology for optimization of sinter mix proportions based on predictive models and adjustment rules[J]. Journal of System Simulation, 2008, 20(9):2423.)

[14] Banihabib M E, Mousavi-Mirkalaei P. Extended linear and non-linear auto-regressive models for forecasting the urban water consumption of a fast-growing city in an arid region[J]. Sustainable Cities and Society, 2019, 48:101585.

